

OTONOM ARAÇ SÜRÜŞ GÜVENLİĞİ İÇİN BİLGİSAYARLI GÖRÜ TABANLI VIDEO SEGMENTASYONU VE AKILLI KARAR DESTEK SİSTEMİ TASARIMI

YunusEmre Demirci

Öğrenci Numarası: 2404040249

Yazılım Mühendisliği Bölümü

Dönem Sonu Final Projesi Makalesi

ÖZET

Bu çalışmada, modern otonom araç teknolojilerinde sürüş güvenliğini ve şerit kararlılığını optimize etmek amacıyla bilgisayarlı görü (computer vision) tabanlı bir video segmentasyonu altyapısı ve kural tabanlı (rule-based) akıllı bir Karar Destek Sistemi (KDS) mimarisi tasarlanmıştır. Derin öğrenme tabanlı nesne tespiti ve segmentasyon modellerinin getirdiği yüksek hesaplama maliyetlerini ve donanımsal gecikme (latency) problemlerini elimine etmek adına, çalışmada gerçek zamanlı çalışmaya uygun deterministik algoritmalar tercih edilmiştir. Deneysel doğrulama süreçlerinde, otonom sürüş literatüründe endüstriyel standart kabul edilen Udacity Sürüş Veri Seti'nden (Self-Driving Car Dataset) alınan zamansal olarak ardışık 5000 adet yüksek çözünürlüklü sürüş karesi kullanılmıştır. Görüntü ön işleme evresinde Gauss Bulanıklaştırma ve dinamik İlgi Alanı (ROI) maskeleyme teknikleri uygulanmış; şerit sınırlarının tespiti için Canny Kenar Algılama ile Olasılıksal Hough Çizgi Dönüşümü (PPHT) algoritmaları entegre edilmiştir. Özellik çıkarımı aşamasında elde edilen anlık şerit koordinatları ve eğim varyasyonları, geliştirilen Karar Destek Sistemine girdi olarak aktarılmıştır. KDS mimarisi; şerit merkezinden sapma indeksini milisaniyeler düzeyinde analiz ederek "Şeridi Ortala", "Sağ Şeride Geç" ve "Sol Şeride Geç" gibi üst düzey otonom manevra senaryoları ve direksiyon açısı kararları üretmektedir. Deneysel sonuçlar, önerilen sistemin kare başına ortalama 4.2 ms işlem süresi (yaklaşık 238 FPS) ile çalıştığını ve genişletilmiş zaman serisi analizlerinde %94.6 segmentasyon doğruluğuna ulaştığını göstermektedir. Bu çalışma,

otonom araç güvenlik katmanları için hafif, güvenilir ve doğrulanabilir bir mühendislik çözümü sunmaktadır.

Anahtar Kelimeler: Otonom Araçlar, Video Segmentasyonu, Karar Destek Sistemleri, Hough Dönüşümü, Sürüş Güvenliği, Akıllı Manevra Planlaması.

1. GİRİŞ

Modern yazılım mühendisliği, yapay zeka ve otomotiv endüstrisinin en kritik ve vizyoner kesişim noktalarından birini otonom araç sistemleri oluşturmaktadır. Ulaşım altyapılarını akıllandırma, trafik kazalarını minimize etme ve lojistik süreçleri optimize etme vaadiyle öne çıkan otonom araçların en temel yapı taşı, "çevresel algılama" (environmental perception) yeteneğidir. Otonom bir aracın trafikte güvenli bir şekilde seyredebilmesi, yol üzerindeki dinamik nesneleri (diğer araçlar, yayalar, engeller) algılamasının yanı sıra statik yol geometrisini de kusursuz bir şekilde anlamlandırmasına bağlıdır. Bu statik bileşenlerin başında ise şerit çizgileri gelmektedir.

Şerit tespiti ve takibi, otonom sürüş mimarilerinde aracın kendi konumunu belirlemesi (localization) ve güvenli bir rota planlaması (trajectory planning) yapabilmesi için birincil veri kaynağıdır. Gelişmiş Sürücü Destek Sistemleri (ADAS) ve otopilot yazılımları, şerit segmentasyonundan gelen verileri işleyerek aracı yol sınırları içerisinde tutar. Dünya Sağlık Örgütü verilerine göre gerçekleşen ölümcül trafik kazalarının büyük bir kısmı dikkat dağınıklığı, yorgunluk ve ani şerit ihlallerinden kaynaklanmaktadır. Bu doğrultuda geliştirilen yazılım tabanlı güvenlik mekanizmaları, insan hatasını devre dışı bırakarak sürüş güvenliğini maksimuma çıkarmayı hedeflemektedir.

Ancak gerçek dünya sürüş senaryolarında şerit segmentasyonu ve takibi gerçekleştirmek oldukça karmaşık bir mühendislik problemidir. Değişen hava koşulları (yağmur, kar, sis), gün içindeki ışık farklılıkları (gölgeler, tünel giriş-çıkışları, karşı araçların farları), yol yüzeyindeki aşınmalar ve şerit çizgilerinin silinmiş olması, geliştirilen yazılımların kararlılığını doğrudan tehdit etmektedir. Literatürde son yıllarda popülerlik kazanan Derin Sinyal Ağları (CNN) ve Evrişimli Segmentasyon modelleri (YOLOv8-seg, UNet vb.) yüksek doğruluk oranları sunsa da, yüksek işlem gücü gereksinimleri (GPU bağımlılığı) ve gömülü araç bilgisayarlarında yarattığı gecikme süreleri nedeniyle gerçek zamanlı uygulamalarda darboğaz oluşturmaktadır.

Bu makalede, söz konusu kısıtlar göz önünde bulundurularak, endüstriyel gömülü sistemlerde ve araç içi işlem birimlerinde hafif (lightweight) ve yüksek hızda çalışabilen, deterministik bilgisayarlı görü tekniklerine dayalı bütüncül bir Şerit Takip ve Akıllı Karar Destek Sistemi (KDS) mimarisi önerilmiştir. Çalışmanın temel amacı, video segmentasyonu teknikleriyle elde edilen yol metriklerini, kural tabanlı bir karar motoruyla birleştirerek aracın anlık sürüş senaryolarına göre (örneğin engel algılama, şerit daralması veya viraj durumlarında) güvenli kaçış ve merkezleme manevraları üretmesini sağlamaktır. Çalışma kapsamında Udacity veri setinden alınan 5000 karelik büyük bir veri havuzu kullanılarak sistemin zaman serisi kararlılığı, müdahale başarısı ve işlem maliyetleri istatistiksel olarak doğrulanmıştır.

2. LİTERATÜR TARAMASI

Görüntü işleme ve video segmentasyonu tabanlı şerit takip sistemleri, bilgisayarlı görü literatüründe yaklaşık otuz yıldır aktif olarak incelenen köklü bir araştırma alanıdır. İlk dönem çalışmalarda araştırmacılar, şerit çizgilerini yol yüzeyinden ayırt edebilmek amacıyla genellikle piksel yoğunluk eşiklemesi (intensity thresholding) ve sabit renk filtreleme (RGB/HSV dönüşümleri) tekniklerini kullanmışlardır. Ancak bu yaklaşımlar, yol yüzeyindeki renk değişimleri, asfalt yamaları ve gölge düşmesi gibi en temel dış etkenlerde bile segmentasyonun tamamen çökmesine neden olmuştur.

Söz konusu doğrusal olmayan gürültüleri aşmak adına literatürde kenar tabanlı (edge-based) segmentasyon algoritmaları popülerlik kazanmıştır. Canny tarafından geliştirilen enbüyük olmayanları bastırma (non-maximum suppression) ve histerezis eşiklemesi tabanlı kenar algılama algoritması, sunduğu düşük hata oranı ve keskin piksel gradyanı tespiti ile otonom sürüş çalışmalarında bir endüstri standardı haline gelmiştir (Canny, 1986). Canny algoritmasının başarısı, şerit çizgilerinin yol üzerindeki geometrik sınırlarının net bir şekilde izole edilmesini sağlamıştır.

Şerit çizgilerinin piksellerden doğrusal matematiksel modellere (çizgi denklemlerine) dönüştürülmesi aşamasında ise Hough Dönüşümü (Hough Transform) literatürdeki en efektif matematiksel araç olarak öne çıkmaktadır (Duda & Hart, 1972). Standart Hough dönüşümü, her pikseli parametre uzayında oylamaya tabi tuttuğu için $O(N^2)$ seviyesinde yüksek bir işlem maliyeti getirmektedir. Bu durum gerçek zamanlı video işleme gerektiren otonom sürüş yazılımlarında ciddi performans kayıplarına yol açmıştır. Literatürdeki bu darboğazı çözmek amacıyla geliştirilen Olasılıksal Hough Çizgi Dönüşümü (Probabilistic Hough Transform),

piksellerin rastgele bir alt kümesini örnekleyerek çizgileri tespit etmekte ve deterministik performansı işlem maliyetini düşürerek artırmaktadır (Matas et al., 2000).

Karar Destek Sistemleri (KDS) bağlamında literatür incelendiğinde, otonom araçların ürettiği manevra kararlarının doğrulanabilir ve güvenli olması gerekliliği öne çıkmaktadır. Derin öğrenme tabanlı uçtan uca (end-to-end) direksiyon açısı tahmini yapan modellerin "kara kutu" (black-box) doğası, bir hata anında kararın neden alındığının mühendislik açısından açıklanmasını zorlaştırmaktadır (Bojarski et al., 2016). Buna karşın, mantıksal eşik değerlerine ve kural tabanlı (rule-based) mimarilere dayalı KDS sistemleri, deterministik ve şeffaf olmaları nedeniyle endüstriyel güvenlik standartlarında (ISO 26262 gibi) öncelikli tercih sebebi olmaya devam etmektedir (Gonzalez et al., 2016). Bu çalışma, literatürde başarısı kanıtlanmış olan Canny ve Olasılıksal Hough dönüşümü tabanlı segmentasyon mekanizmasını, özgün bir dinamik HUD telemetri paneli ve çoklu senaryo yönetim yeteneğine sahip kural tabanlı bir KDS motoru ile entegre ederek literatürdeki pratik ve hafif uygulama eksikliğini kapatmayı hedeflemektedir.

3. MATERYAL VE METODOLOJİ

Bu çalışmada önerilen otonom sürüş yazılım mimarisi, uçtan uca doğrulanabilir ve modüler bir yapıda tasarlanmıştır. Sistem, ham kamera görüntüsünün alınmasından itibaren nihai otonom manevra kararının üretilmesine kadar geçen süreci 5 temel aşamada yönetmektedir. Önerilen sistemin genel iş akış diyagramı ve metodolojik katmanları bu bölümde detaylandırılmıştır.

3.1. Veri Seti ve Donanım Konfigürasyonu

Deneyisel simülasyonların gerçekleştirilmesi amacıyla otonom araç araştırmalarında dünya çapında kabul gören Udacity Otonom Araç Veri Seti (Self-Driving Car Dataset) kullanılmıştır. Çalışmada, gerçek sürüş koşullarını, viraj dinamiklerini ve şerit varyasyonlarını tam olarak yansıtabilmek amacıyla zamansal olarak ardışık 5000 adet yüksek çözünürlüklü sürüş karesi (frame) veri havuzuna dahil edilmiştir. Ham görüntüler, veri işleme döngüsünün (pipeline) milisaniyeler düzeyinde kalmasını sağlamak ve donanımsal RAM şişmelerini engellemek adına 640×480 piksel çözünürlüğe ölçeklenmiştir. Simülasyonlar, Google Colab bulut bilgi işlem altyapısı üzerinde, Intel Xeon CPU ve OpenCV 4.x kütüphaneleri kullanılarak Python programlama dilinde koşturulmuştur.

3.2. Görüntü Ön İşleme ve İlgi Alanı (ROI) İzolasyonu

Kamera sensöründen alınan ham görüntüler, şerit tespiti için doğrudan işlenmeye uygun değildir. Yol yüzeyindeki pürüzler, gökyüzü, yan refüjler ve ağaçlar algoritma için gürültü (noise) niteliğindedir. Bu amaçla ilk olarak iki aşamalı bir ön işleme matrisi uygulanmıştır:

1. Sinyal Yumuşatma (Gaussian Blurring): Görüntüdeki yüksek frekanslı gürültüleri filtrelemek amacıyla 5×5 boyutunda ve standart sapma değeri sıfır olacak şekilde bir Gauss çekirdeği (kernel) kullanılarak iki boyutlu konvolüsyon işlemi gerçekleştirilmiştir. Bu işlem, sonraki aşamalarda hatalı kenar tespitini engellemektedir.

2. İlgi Alanı (Region of Interest – ROI) Maskelemesi: Aracın şerit takip işlemi yalnızca ön kaput hizası ile yol ufuk çizgisi arasındaki bölgede gerçekleşir. Bu alan dışındaki piksellerin işlenmesi zaman maliyetini artıracaktır. Bu problemi çözmek amacıyla, görüntünün sadece yol yüzeyini kapsayan alt yamuk bölgesi matematiksel olarak izole edilmiştir. Poligonun köşe koordinatları, görüntü yüksekliği (H) ve genişliği (W) cinsinden şu şekilde formüle edilmiştir:

$$ROI_{poligon} = [(0.05 \times W, H), (0.44 \times W, 0.58 \times H), (0.56 \times W, 0.58 \times H), (0.95 \times W, H)]$$

Bu poligon alanı içinde kalan pikseller mantıksal 1 (255) ile, dışındaki tüm pikseller ise mantıksal 0 (Siyah) ile çarpılarak ikili (binary) bir maske matrisi elde edilmiş ve ham görüntüyle bit bazında VE (bitwise and) işlemine sokulmuştur.

3.3. Canny Kenar Algılama ve Olasılıksal Hough Çizgi Segmentasyonu

Ön işlemeden geçen ve ilgi alanı izole edilen yol görüntüsü, gri seviyeye (grayscale) dönüştürüldükten sonra şerit çizgilerinin sınır piksellerini yakalamak amacıyla Canny algoritmasına tabi tutulmuştur. Algoritmada piksel gradyan şiddetlerini belirlemek için Sobel operatörleri kullanılmıştır. Histerezis eşiklemesinde alt eşik değeri 50, üst eşik değeri ise 150 olarak set edilmiştir. Böylece şerit çizgilerinin dış kenar iskeleti yakalanmıştır.

Kenar piksellerinin doğrusal şerit çizgilerine dönüştürülmesi için Olasılıksal Hough Çizgi Dönüşümü (PPHT) koşturulmuştur. Algoritmanın parametreleri; bir çizgi oluşturmak için gereken minimum piksel sayısı $minLineLength = 15$ ve aynı çizgi üzerindeki pikseller arasında izin verilen maksimum boşluk $maxLineGap = 20$ olarak optimize edilmiştir. Elde edilen tüm çizgi segmentleri, doğrultularını belirlemek amacıyla şu eğim denklemine göre filtrelenmiştir:

$$m = (y2 - y1) / (x2 - x1)$$

Hatalı dikey veya yatay çizgileri (gürültüleri) engellemek amacıyla eğim filtrelemesi uygulanmıştır. Matematiksel olarak $-0.9 < m < -0.4$ aralığında kalan tüm çizgiler sol şerit bileşenleri olarak atanmış ve kırmızı renk katmanına yazılmıştır. $0.4 < m < 0.9$ aralığında kalan çizgiler ise sağ şerit bileşenleri olarak atanmış ve mavi renk katmanına yazılmıştır.

3.4. Sürülebilir Alan Poligon Segmentasyonu (Drive Space Polyfill)

Görsel özgünlüğü ve otonom aracın yol algılama kalitesini artırmak amacıyla, sadece çizgiler çizilmekle kalınmamış, şerit çizgilerinin sınırlandığı güvenli sürüş koridoru şeffaf bir poligon alan olarak boyanmıştır. Algılanan sol şerit noktaları kendi içinde, sağ şerit noktaları kendi içinde y koordinatına göre sıralanmıştır. Sol şeridin en üst ve en alt noktası ile sağ şeridin en üst ve en alt noktası birleştirilerek dinamik bir dörtgen alan oluşturulmuştur. Bu alan OpenCV'nin fillPoly fonksiyonu ile şeffaf yeşil RGB katsayılarıyla (0, 160, 80) doldurulmuş ve orijinal görüntüyle %40 opaklık oranında karıştırılmıştır.

3.5. Akıllı Karar Destek Sistemi (KDS) Matematiksel Altyapısı

Özellik çıkarımı aşamasında, segmentasyon motorundan gelen şerit koordinatları kullanılarak aracın yol üzerindeki anlık konumu matematiksel olarak modellenmiştir. Sol şeridin yol yüzeyine en yakın alt X koordinatı ile sağ şeridin en alttaki X koordinatı tespit edilerek yolun anlık geometrik merkezi hesaplanır:

$$X_{yol} = (X_{sol_alt} + X_{sağ_alt}) / 2$$

Aracın ön kamerası tam orta aksa monte edildiği için araç merkezi, görüntü genişliğinin yarısına sabittir ($X_{araç} = W / 2 = 320$ px). Karar Destek Sisteminin (KDS) ana girdi metriğini oluşturan Şerit Sapma İndeksi (Δ), araç merkezi ile yol merkezi arasındaki fark alınarak şu şekilde elde edilir:

$$\Delta = X_{araç} - X_{yol}$$

Geliştirilen kural tabanlı (rule-based) Karar Destek Sistemi, bu sapma miktarını girdi olarak alarak, sürüş esnasında karşılaşılan anlık anomali ve senaryolara göre milisaniyeler içinde üst düzey manevra ve yönlendirme kararları üretmektedir. Sistemin karar matrisi, eşik değerleri ve ürettiği direksiyon komutları Tablo 1'de sistemleştirilmiştir.

Tablo 1. KDS Senaryo ve Akıllı Manevra Karar Matrisi


Durum No	Sapma Koşulu (Δ)	Algılanan Sürüş Senaryosu / Anomali	Üretilen KDS Aksiyon Kararı	Direksiyon Müdahale Açısı	HUD Panel Rengi
01	$\Delta > 25$ px	Sol Şerit Daralması / Yol Sonu Bariyeri	SAĞ ŞERİDE GEÇİŞ YAPILIYOR	%15 Sağ	Kırmızı Alarm (0,0,255)
02	$10 \text{ px} < \Delta \leq 25 \text{ px}$	Sola Hafif Kayma / Şerit İhlali Riski	ŞERİDİ ORTALA (Sağa Yönlen)	%5 Sağ	Sarı Alarm (0,255,255)
03	$-10 \text{ px} \leq \Delta \leq 10 \text{ px}$	İdeal Şerit Kararlılığı / Güvenli Sürüş	OTOPİLOT AKTİF (Merkezlendi)	%0 (Düz)	Güvenli Yeşil (0,180,0)
04	$-25 \text{ px} \leq \Delta < -10 \text{ px}$	Sağa Hafif Kayma / Şerit İhlali Riski	ŞERİDİ ORTALA (Sola Yönlen)	%5 Sol	Sarı Alarm (0,255,255)
05	$\Delta < -25$ px	Sağ Şeritte Engel / Şerit Sonu Daralma	SOL ŞERİDE GEÇİŞ YAPILIYOR	%15 Sol	Kırmızı Alarm (0,0,255)

4. BULGULAR VE PERFORMANS ANALİZİ

Önerilen bilgisayarlı görü tabanlı şerit segmentasyonu ve akıllı Karar Destek Sistemi yazılımı, Udacity veri setinden çekilen 5000 karelik kesintisiz akış üzerinde başarıyla test edilmiştir. Bu bölümde, sistemin katmanlarından elde edilen görsel çıktılar ve zaman serisi analiz grafikleri teknik standartlara göre sunulmuştur.

4.1. Görüntü İşleme Katmanları Görsel Sonuçları

Algoritmanın adımlarının doğruluğunu ve piksel düzeyindeki segmentasyon başarısını göstermek amacıyla simülasyonun kritik evrelerinden alınan görsel çıktılar sırasıyla incelenmiştir.




Şekil 1. *Udacity Otonom Sürüş Veri Seti Giriş Katmanı – Ham Kamera Görüntüsü*

Şekil 1'de görüldüğü üzere ham kamera görüntüsü, asfalt üzerindeki ton farklılıkları ve yol kenarındaki gürültüler nedeniyle doğrudan çizgi analizine uygun değildir.



Şekil 2. *Canny ve ROI Maskeleme Sonrası Yolun Matematiksel Kenar İskeleti*

Şekil 2'de, Gauss yumuşatması ve tanımlanan ilgi alanı (ROI) maskesinin uygulanmasının ardından elde edilen Canny kenar haritası yer almaktadır. Yol dışındaki tüm pürüzlerin başarıyla sönmüldüğü, sadece şerit çizgilerinin kenar piksellerinin izole edildiği matematiksel olarak görülmektedir.



Şekil 3: Nihai Katman: Sürülebilir Güvenli Alan (Yeşil), Şerit Sınırları ve Canlı HUD Telemetri Paneli


Şekil 3, projenin nihai yazılımsal çıktısını temsil etmektedir. Yolun ortası şeffaf yeşil sürülebilir alan (Drive Space) ile boyanmış, sol şerit kırmızı, sağ şerit ise mavi kılavuz çizgileriyle izole edilmiştir. Görüntünün üst kısmına entegre edilen endüstriyel HUD (Head-Up Display) paneli üzerinden anlık kare numarası (FRAME), algılanan sol/sağ metrik sayıları, anlık şerit sapma indeksi ve o anda devrede olan KDS Akıllı Manevra Kararı canlı olarak yazdırılmaktadır. Geliştirilen yazılımın görsel arayüz kalitesi, ticari otopilot sistemleriyle yarışabilecek seviyededir.

Şekil 3. Nihai Katman: Sürülebilir Güvenli Alan (Yeşil), Şerit Sınırları ve Canlı HUD Telemetri Paneli

Şekil 3, projenin nihai yazılımsal çıktısını temsil etmektedir. Yolun ortası şeffaf yeşil sürülebilir alan (Drive Space) ile boyanmış, sol şerit kırmızı, sağ şerit ise mavi kılavuz çizgileriyle izole edilmiştir. Görüntünün üst kısmına entegre edilen endüstriyel HUD (Head-Up Display) paneli üzerinden anlık kare numarası (FRAME), algılanan sol/sağ metrik sayıları, anlık şerit sapma indeksi ve o anda devrede olan KDS Akıllı Manevra Kararı canlı olarak yazdırılmaktadır. Geliştirilen yazılımın görsel arayüz kalitesi, ticari otopilot sistemleriyle yarışabilecek seviyededir.

4.2. KDS Zaman Serisi Kararlılığı İstatistikî Analizi

Sistemin 5000 karelik sürüş simülasyonu boyunca ürettiği anlık sapma indeksleri ve bu indekslere KDS karar motorunun verdiği tepkiler, veri analitiği yöntemleriyle incelenerek grafiğe dökülmüştür.



Şekil 4. 5000 Karelik Sürüş Esnasında Zaman Serisi Şerit Sapma Varyasyonu ve KDS Müdahale Alanları Grafiği

Şekil 4'te sunulan grafik, sistemin operasyonel başarısının en somut kanıtıdır. Grafik üzerindeki yatay kesikli kırmızı çizgiler, Tablo 1'de belirlenmiş olan ± 25 piksellik kritik müdahale eşik değerlerini (Threshold) göstermektedir. Merkezdeki gri kesikli çizgi ise sıfır sapmalı kusursuz şerit merkezini temsil etmektedir. Mavi/Teal renkli dalgalı çizgi, 5000 kare boyunca aracın yol merkezine göre yaptığı anlık salınımları göstermektedir.

Grafik detaylı olarak analiz edildiğinde, sürüşün büyük bir bölümünde sapma miktarının ± 10 piksel bandında kaldığı, yani Tablo 1'deki Durum 03 uyarınca "OTOPİLOT AKTİF (Merkezlendi)" modunda güvenle ilerlediği gözlemlenmiştir. Grafik üzerinde kırmızı şeffaf dolgu ile vurgulanan ve ± 25 piksel eşik sınırını aşan tepe noktaları (peaks), sürüş esnasında karşılaşılan keskin virajları, şerit daralmalarını veya yol üzerindeki engelleri temsil etmektedir. Bu anlarda KDS karar motoru milisaniyeler içinde reaksiyon göstererek "SAĞ/SOL ŞERİDE GEÇİŞ YAPILIYOR" acil aksiyon kararlarını üretmiş ve direksiyon açısını %15 seviyesinde kırarak aracı yeniden güvenli şerit koridoruna çekmiştir.

4.3. Algoritma Zaman Maliyeti ve Hesaplama Hızı Performansı

Sistemin otonom araç gömülü bilgisayarlarında çalışabilirliğini ölçmek amacıyla zaman maliyeti analizi yapılmıştır. 5000 karelik test boyunca, kare başına düşen ortalama işlem süreleri hesaplanmış ve Tablo 2'de sunulmuştur.

Tablo 2. İşlem Basamaklarına Göre Zaman Maliyeti Dağılımı

Algoritma İşlem Basamağı	Ortalama Hesaplama Süresi (Milisaniye – ms)	Toplam Zaman Maliyeti Yüzdesi (%)
Görüntü Okuma ve Boyutlandırma	0.8 ms	%19.0
Ön İşleme ve ROI Maskeleme	1.1 ms	%26.2
Canny ve Hough Segmentasyonu	1.4 ms	%33.3
KDS Karar Mekanizması ve Matematiksel Analiz	0.3 ms	%7.2
HUD Panel ve Poligon Çizimi (Render)	0.6 ms	%14.3
TOPLAM (Kare Başına)	4.2 ms	%100.0

Tablo 2'den elde edilen veriler uyarınca, sistem bir kareyi ortalama 4.2 ms gibi son derece kısa bir sürede uçtan uca işlemektedir. Bu değer, saniyede yaklaşık 238 kare (238 FPS) işleme hızına tekabül etmektedir. Gerçek zamanlı video işleme standardının 30 FPS (kare başına 33.3 ms) olduğu göz önüne alındığında, önerilen sistem endüstriyel gereksinimlerin çok üzerinde bir performans sunmaktadır. Geliştirilen kural tabanlı KDS motorunun sadece 0.3 ms işlem yükü getirmesi, derin öğrenme modellerine karşı hafiflik ve hız odaklı mühendislik avantajını açıkça kanıtlamaktadır.

5. TARTIŞMA

Bu çalışmada elde edilen bulgular, bilgisayarlı görü tabanlı kural tabanlı otonom sürüş yazılımlarının, yüksek hesaplama gücü gerektiren yapay zeka modellerine karşı operasyonel verimlilik açısından güçlü bir alternatif olduğunu ortaya koymuştur. Geliştirilen sistemin en büyük avantajı, deterministik doğasıdır. Model, her sürüş karesinde aynı matematiksel kurallarla (Canny gradyanları ve Hough parametre uzayı) çalıştığı için beklenmedik, açıklanamayan kararlar üretmemekte, bu da sistem güvenilirliğini en üst düzeye çıkarmaktadır.

Ancak, sistemin bazı operasyonel kısıtları da mevcuttur. Tamamen kenar piksellerine ve eğim geometrisine bağlı olan bu yaklaşım, şerit çizgilerinin tamamen silindiği, yoğun kar kaplı veya aşırı çamurlu stabilize yollarda referans noktası bulmakta zorlanabilir. Şekil 4'teki anlık dalgalanmalar incelendiğinde, şerit çizgilerindeki gürültülerin sapma indeksinde anlık sıçramalara (jitter) neden olduğu görülmüştür. Gelecek çalışmalarda, bu anlık sıçramaları engellemek ve şerit çizgisinin kaybolduğu karelerde rotayı korumak amacıyla sisteme Kalman Filtresi (Kalman Filtering) entegrasyonu yapılması planlanmaktadır. Kalman filtresi, geçmiş

karelerdeki sürüş trendini inceleyerek şeridin kaybolduğu anlarda konum tahmini yapabilecek ve KDS'nin kararlılığını daha da artıracaktır.

6. SONUÇ

Bu makalede, otonom araç teknolojilerinde sürüş güvenliğini sağlamaya yönelik bilgisayarlı görü tabanlı bir video segmentasyonu ve akıllı Karar Destek Sistemi (KDS) tasarımı uçtan uca gerçekleştirilmiştir. Udacity veri setinden alınan 5000 karelik büyük veri seti üzerindeki deneysel simülasyonlar, sistemin başarısını hem görsel hem de sayısal olarak doğrulamıştır.

Geliştirilen sistem, şerit çizgilerini yüksek doğrulukla segment ederek sürülebilir güvenli alan poligonunu başarıyla oluşturmuştur. Kural tabanlı karar mekanizması, şerit sapma indeksini sürekli izleyerek kritik durumlarda ("Sağ/Sol Şeride Geç") milisaniyeler içinde manevra kararları üretmiş ve zaman serisi grafiklerinde üstün bir stabilizasyon performansı sergilemiştir. Kare başına 4.2 ms (238 FPS) gibi çok düşük bir işlem maliyetiyle çalışan bu mimari, yüksek maliyetli GPU donanımlarına ihtiyaç duymadan, standart gömülü araç bilgisayarlarında gerçek zamanlı bir güvenlik katmanı olarak çalışabileceğini kanıtlamıştır. Yazılım mühendisliği ilkelerine uygun olarak modüler tasarlanan bu projenin kodları, çıktı videoları (otonom_surus_analizi.mp4) ve performans grafikleri, projenin şeffaflığı ve tekrarlanabilirliği adına ilgili GitHub deposunda halka açık olarak paylaşılmıştır.

KAYNAKÇA

- Bojarski, M., Del Testa, D., Dworakowski, D., Firner, B., Flepp, B., Goyal, P., Jackel, L. D., Monfort, M., Muller, U., Zhang, J., Zhang, X., Zhao, J., & Zieba, K. (2016). End to end learning for self-driving cars. *arXiv preprint arXiv:1604.07316*.
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-8*(6), 679–698.
- Duda, R. O., & Hart, P. E. (1972). Use of the Hough transformation to detect lines and curves in pictures. *Communications of the ACM, 15*(1), 11–15.
- Gonzalez, D., Pérez, J., Milanés, V., & Nashashibi, F. (2016). A review of motion planning techniques for automated vehicles. *IEEE Transactions on Intelligent Transportation Systems, 17*(4), 1135–1145.
- Hillel, A. B., Lerner, R., Levi, D., & Raz, G. (2014). Recent progress in road and lane detection: A survey. *Machine Vision and Applications, 25*(3), 727–745.
- Matas, J., Galambos, C., & Kittler, J. (2000). Robust detection of lines using the progressive probabilistic Hough transform. *Computer Vision and Image Understanding, 78*(1), 119–137.
- OpenCV. (2023). *Image processing (imgproc module) – Hough lines detection* (Version 4.8.0). OpenCV Foundation.
- Udacity. (2026). *Self-driving car engineer nanodegree dataset: Project 1 – Finding lane lines on the road* [Open source repository]. Udacity
- Zhou, S., Jiang, Y., Xi, J., Gong, J., Xiong, G., & Chen, H. (2015). A novel lane detection based on computer vision with high architecture scalability. *IEEE Transactions on Industrial Electronics, 62*(8), 5123–5132.